

# Proyecto Final ML - ICFES Saber 11

Carlos Manuel Carvajales Castrillo and Mateo Ruiz Mendoza

**Abstract**—This work presents a machine learning approach for predicting student performance levels in the Colombian *Saber 11* standardized examination using exclusively socioeconomic and contextual variables. The study leverages more than one million records obtained from the official open-data platform of the Colombian government for the 2022 academic periods 20221 and 20224. To prevent data leakage, all subject-specific and global score variables were excluded from the predictive feature space and used solely for target construction. The proposed methodology includes data acquisition through the Socrata Open Data API, exploratory data analysis, duplicate detection, missing-value analysis, feature preprocessing, and the comparison of multiple machine learning models. The project aims to evaluate the feasibility of predicting educational outcomes from contextual information and to identify relevant socioeconomic factors associated with academic performance.

**Impact Statement**—Educational inequality remains one of the principal social challenges in Colombia. The ability to anticipate low academic performance using contextual and socioeconomic information can support early intervention strategies in vulnerable student populations before standardized examinations are taken.

This study contributes to the field of Educational Data Mining by proposing a predictive framework that avoids information leakage and focuses exclusively on environmental and demographic factors. The results may support educational institutions and policymakers in identifying high-risk populations, designing targeted support programs, and understanding the influence of socioeconomic conditions on academic achievement.

Additionally, the methodology provides a reproducible pipeline for large-scale educational data analysis using public governmental datasets.

**Index Terms**—Educational Data Mining, Machine Learning, Saber 11, Student Performance Prediction, Socioeconomic Factors, Classification, Data Mining, Colombia.

## I. INTRODUCCIÓN

Las pruebas *Saber 11*, administradas por el *Instituto Colombiano para la Evaluación de la Educación (ICFES)*, constituyen el examen estandarizado más importante para los estudiantes de educación media en Colombia. Cada año, cientos de miles de estudiantes presentan esta prueba, generando uno de los conjuntos de datos educativos más grandes y relevantes del país.

El desempeño académico en pruebas estandarizadas no depende únicamente de las capacidades individuales de los estudiantes. Factores socioeconómicos, condiciones familiares, acceso a recursos tecnológicos y características institucionales también influyen significativamente en los resultados obtenidos.

En este contexto, el presente trabajo aborda la siguiente pregunta de investigación:

*¿Es posible predecir el nivel de desempeño global de un estudiante en las pruebas Saber 11 utilizando exclusivamente variables socioeconómicas*

*y contextuales, sin emplear los puntajes específicos obtenidos en las distintas áreas evaluadas?*

Esta pregunta resulta relevante debido a que permitiría identificar estudiantes en riesgo antes de la presentación de la prueba, facilitando estrategias de intervención temprana por parte de instituciones educativas y entidades gubernamentales.

Adicionalmente, excluir los puntajes individuales y el puntaje global de las variables predictoras evita problemas de *data leakage*, garantizando una evaluación más realista del desempeño de los modelos de aprendizaje automático.

El objetivo principal de este proyecto consiste en construir y evaluar un sistema de clasificación multiclase capaz de predecir el nivel de desempeño de los estudiantes utilizando únicamente variables contextuales y socioeconómicas. Para ello, se consideran cuatro enfoques de aprendizaje automático: Regresión Logística, Random Forest, XGBoost y Redes Neuronales Artificiales.

## II. METODOLOGÍA

### A. Fuente y Adquisición del Dataset

El dataset utilizado en este estudio fue obtenido desde el portal de datos abiertos del Gobierno de Colombia, *datos.gov.co*, utilizando el identificador oficial `kgxf-xxbe` correspondiente a los resultados únicos de las pruebas Saber 11.

Para el desarrollo del proyecto se seleccionaron exclusivamente los períodos académicos 20221 y 20224 debido a las siguientes razones:

- Corresponden a los períodos más recientes con información completa disponible.
- Ambos pertenecen al mismo año académico, reduciendo posibles sesgos temporales.
- En conjunto contienen más de un millón de registros, garantizando robustez estadística.
- Permiten capturar variaciones entre ambos semestres del mismo año.

La extracción de los datos se realizó mediante la API pública de Socrata Open Data API (SODA), implementando un mecanismo de descarga paginada en Python.

Con el fin de garantizar estabilidad en la descarga y evitar restricciones por límite de solicitudes, se utilizó un tamaño de página de 10 000 registros por petición, incorporando además mecanismos automáticos de reintento y pausas entre solicitudes consecutivas.

El dataset bruto obtenido contiene 51 variables asociadas a información demográfica, institucional, socioeconómica y resultados de las pruebas.

### B. Validación de la Descarga

Posteriormente a la adquisición de los datos, se realizaron diferentes validaciones orientadas a garantizar la integridad y completitud del dataset.

Se verificó la presencia de ambos períodos seleccionados y se inspeccionaron las dimensiones generales del conjunto de datos. El dataset final obtenido contiene 1 085 937 registros y 51 variables.

Asimismo, se confirmó correctamente la presencia de los períodos 20221 y 20224 dentro de la información descargada.

### C. Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos (EDA) tuvo como propósito comprender la estructura general del dataset, identificar problemas de calidad de datos, analizar patrones de valores faltantes y fundamentar las decisiones posteriores de preprocesamiento y modelado.

1) *Estructura General y Tipos de Variables*: La inspección inicial del dataset evidenció que la mayoría de variables fueron almacenadas como objetos categóricos, incluyendo variables socioeconómicas y puntajes de las pruebas.

Por esta razón, las variables numéricas asociadas a puntajes fueron convertidas explícitamente a tipos numéricos antes de realizar el análisis estadístico descriptivo.

El dataset contiene diferentes grupos de variables:

- Variables demográficas.
- Variables institucionales asociadas al establecimiento educativo.
- Variables socioeconómicas del entorno familiar.
- Variables relacionadas con los puntajes obtenidos en las pruebas.

2) *Análisis de Valores Nulos*: Se realizó un análisis detallado de valores faltantes con el objetivo de identificar variables incompletas y evaluar el impacto potencial de distintas estrategias de tratamiento de nulos.

La Tabla I presenta las variables con mayor porcentaje de datos faltantes.

TABLE I  
VARIABLES CON MAYOR PORCENTAJE DE VALORES NULOS

| Variable             | Nulos (%) |
|----------------------|-----------|
| cole_bilingue        | 18.144    |
| fami_estratovivienda | 6.712     |
| fami_tieneinternet   | 5.919     |
| fami_educacionmadre  | 5.800     |
| fami_educacionpadre  | 5.780     |
| fami_tieneautomovil  | 4.606     |
| fami_cuartoshogar    | 4.444     |
| fami_tienelavadora   | 4.428     |
| fami_tienecomputador | 4.415     |
| fami_personashogar   | 4.286     |

La distribución de valores faltantes se presenta en la Fig. 1.

Los patrones observados sugieren que varias variables socioeconómicas no presentan mecanismos de ausencia completamente aleatorios. Particularmente, variables asociadas al contexto familiar y nivel socioeconómico presentan porcentajes moderados de omisión, posiblemente relacionados con ausencia de reporte o autodeclaración incompleta.




Fig. 1. Porcentaje de valores nulos por variable.

Estos hallazgos motivaron la evaluación de dos estrategias distintas de tratamiento de datos faltantes en etapas posteriores del proyecto:

- Eliminación de registros incompletos.
- Imputación de valores faltantes.

3) *Análisis de Duplicados*: La variable `estu_consecutivo` fue utilizada como identificador principal para detectar registros duplicados.

Durante el análisis se identificó una cantidad significativa de duplicados. Aunque el dataset bruto contenía inicialmente 1 085 937 registros, únicamente se encontraron 552 841 identificadores únicos.

Una inspección detallada evidenció que los registros duplicados correspondían a copias exactas entre sí, lo que sugiere problemas asociados al proceso de adquisición de datos me-

diante paginación y no múltiples observaciones reales de un mismo estudiante.

La Tabla II presenta un ejemplo de registros duplicados identificados durante el análisis.

TABLE II  
EJEMPLO DE REGISTROS DUPLICADOS

| ID               | Período | Género | Puntaje Global |
|------------------|---------|--------|----------------|
| SB11202240000034 | 20224   | M      | 197            |
| SB11202240000034 | 20224   | M      | 197            |
| SB11202240000036 | 20224   | M      | 159            |
| SB11202240000036 | 20224   | M      | 159            |

Como decisión de preprocesamiento, se eliminaron los registros duplicados utilizando una estrategia `keep='first'`, preservando únicamente una instancia por identificador de estudiante.

4) *Distribución del Puntaje Global*: Antes de construir la variable objetivo, se realizó un análisis descriptivo de los puntajes obtenidos en las pruebas Saber 11.

La Tabla IV resume las estadísticas descriptivas de las variables numéricas asociadas a los puntajes.

TABLE III  
ESTADÍSTICAS DESCRIPTIVAS DE LOS PUNTAJES

| Variable                 | Media  | Std   | Min | 25% | 50% | 75% | Max |
|--------------------------|--------|-------|-----|-----|-----|-----|-----|
| punt_ingles              | 50.11  | 13.33 | 0   | 39  | 49  | 58  | 100 |
| punt_matematicas         | 50.71  | 12.30 | 0   | 42  | 51  | 59  | 100 |
| punt_c_naturales         | 49.20  | 10.46 | 0   | 41  | 48  | 57  | 100 |
| punt_sociales_ciudadanas | 47.83  | 12.00 | 0   | 38  | 47  | 57  | 100 |
| punt_lectura_critica     | 52.91  | 10.82 | 0   | 45  | 53  | 61  | 100 |
| punt_global              | 250.78 | 52.25 | 0   | 210 | 247 | 288 | 477 |

Las estadísticas descriptivas evidencian una variabilidad moderada en todas las áreas evaluadas. El puntaje global presenta una media aproximada de 251 puntos y una desviación estándar cercana a 52 puntos, indicando heterogeneidad significativa en el desempeño académico de los estudiantes.

Estas métricas sirvieron posteriormente como base para la construcción de la variable objetivo categórica asociada al nivel de desempeño estudiantil.

5) *Verificación de Duplicados*: Con el fin de determinar si los registros duplicados correspondían a inconsistencias reales o simplemente a réplicas exactas generadas durante la adquisición de datos, se realizó una validación adicional sobre grupos de registros con el mismo identificador `estu_consecutivo`.

El análisis evidenció que los registros duplicados correspondían a filas completamente idénticas en todas sus variables, lo que confirma que el problema estaba asociado al proceso de descarga mediante paginación y no a múltiples observaciones válidas de un mismo estudiante.

Por esta razón, se decidió eliminar los registros duplicados utilizando una estrategia `keep='first'`, conservando únicamente una instancia por estudiante.

6) *Distribución del Puntaje Global*: Con el propósito de fundamentar la posterior construcción de la variable objetivo categórica, se realizó un análisis descriptivo de la distribución del puntaje global y de los puntajes por componente.

Inicialmente, todas las variables de puntaje fueron convertidas explícitamente a tipos numéricos utilizando coerción de errores para garantizar consistencia en el análisis estadístico.

La Tabla IV presenta las estadísticas descriptivas de los puntajes obtenidos en las diferentes áreas evaluadas.

TABLE IV  
ESTADÍSTICAS DESCRIPTIVAS DE LOS PUNTAJES

| Variable                 | Media  | Std   | Min | 25% | 50% | 75% | Max |
|--------------------------|--------|-------|-----|-----|-----|-----|-----|
| punt_ingles              | 50.11  | 13.33 | 0   | 39  | 49  | 58  | 100 |
| punt_matematicas         | 50.71  | 12.30 | 0   | 42  | 51  | 59  | 100 |
| punt_c_naturales         | 49.20  | 10.46 | 0   | 41  | 48  | 57  | 100 |
| punt_sociales_ciudadanas | 47.83  | 12.00 | 0   | 38  | 47  | 57  | 100 |
| punt_lectura_critica     | 52.91  | 10.82 | 0   | 45  | 53  | 61  | 100 |
| punt_global              | 250.78 | 52.25 | 0   | 210 | 247 | 288 | 477 |

La distribución del puntaje global se ilustra en la Fig. 2. El histograma evidencia una distribución aproximadamente unimodal con ligera asimetría positiva, mientras que el boxplot por período permite comparar la estabilidad de los puntajes entre ambos semestres analizados.

Asimismo, se incluyeron líneas de referencia asociadas a los umbrales preliminares de categorización del desempeño estudiantil.




Fig. 2. Distribución del puntaje global y comparación por período.

Los resultados muestran una media aproximada de 251 puntos y una desviación estándar cercana a 52 puntos, indicando una variabilidad considerable en el desempeño académico de los estudiantes evaluados.

Adicionalmente, se observan valores mínimos iguales a cero en múltiples componentes de la prueba. Estos registros podrían estar asociados a ausentismo, anulaciones o inconsistencias administrativas, por lo que serán considerados en etapas posteriores del preprocesamiento.

7) *Análisis de Correlación entre Puntajes*: Con el objetivo de evaluar la relación lineal entre los distintos componentes evaluados y el puntaje global, se calculó la matriz de correlación de Pearson entre todas las variables de puntaje.

La Fig. 3 presenta el mapa de calor de correlaciones obtenido.




Fig. 3. Correlación entre puntajes por componente.

Los resultados evidencian una alta correlación positiva entre los puntajes específicos por componente y el puntaje global, lo cual era esperado dado que el puntaje global se deriva directamente del desempeño agregado en las diferentes áreas evaluadas.

Este hallazgo valida metodológicamente la decisión de excluir todas las variables de puntaje del conjunto de predictores utilizado en los modelos de aprendizaje automático, evitando así problemas de *data leakage* que podrían producir estimaciones artificialmente optimistas del desempeño predictivo.

8) *Variables Socioeconómicas y del Entorno Escolar*: Con el fin de caracterizar el contexto socioeconómico y educativo de los estudiantes incluidos en el estudio, se analizaron diversas variables categóricas relacionadas con estrato socioeconómico, naturaleza del establecimiento educativo, ubicación geográfica y nivel educativo de los padres.

La Fig. 4 presenta la distribución del estrato socioeconómico de los estudiantes.




Fig. 4. Distribución del estrato socioeconómico.

Los resultados evidencian una fuerte concentración de estudiantes en estratos socioeconómicos bajos y medios-bajos. Aproximadamente el 60% de los registros pertenecen a estratos 1 y 2, mientras que menos del 3% corresponden a estratos 5 y 6.

Este comportamiento refleja la composición socioeconómica predominante de la población estudiantil evaluada por el ICFES y sugiere la existencia de importantes desigualdades estructurales en el acceso a recursos educativos.

Adicionalmente, la presencia de aproximadamente un 6.7% de valores faltantes en esta variable refuerza la hipótesis de mecanismos de ausencia no completamente aleatorios.

La Fig. 5 muestra la distribución de la naturaleza de los establecimientos educativos.




Fig. 5. Distribución de la naturaleza del establecimiento educativo.

Se observa que aproximadamente el 76% de los estudiantes provienen de instituciones oficiales, mientras que cerca del 24% pertenecen a colegios no oficiales.

Esta distribución es consistente con la estructura general del sistema educativo colombiano, donde la educación pública concentra la mayor proporción de estudiantes.

La distribución del área geográfica de los establecimientos educativos se presenta en la Fig. 6.




Fig. 6. Distribución del área geográfica del establecimiento educativo.

Los resultados indican que aproximadamente el 83% de los estudiantes pertenecen a instituciones ubicadas en zonas urbanas, mientras que cerca del 17% provienen de áreas rurales.

Esta diferencia evidencia la concentración de la población estudiantil en centros urbanos y sugiere posibles brechas de acceso y calidad educativa entre contextos urbanos y rurales.

La Fig. 7 presenta la distribución de la variable asociada a colegios bilingües.




Fig. 7. Distribución de colegios bilingües.

Se observa que únicamente cerca del 1.4% de los estudiantes pertenecen a instituciones bilingües, mientras que más del 80% provienen de colegios no bilingües.

Asimismo, esta variable presenta aproximadamente un 18% de valores faltantes, constituyéndose como la variable con mayor proporción de datos ausentes dentro del dataset.

Las Fig. 8 y 9 presentan la distribución del nivel educativo de las madres y padres de los estudiantes, respectivamente.




Fig. 8. Distribución del nivel educativo de la madre.




Fig. 9. Distribución del nivel educativo del padre.

En ambos casos, predominan niveles educativos asociados a educación secundaria completa o incompleta. Sin embargo,

también se observa una proporción importante de estudiantes cuyos padres poseen únicamente educación primaria o niveles inferiores.

Particularmente, el porcentaje de educación profesional completa y posgrado resulta considerablemente menor frente a niveles educativos básicos y medios.

Estos resultados son relevantes debido a que múltiples estudios en minería de datos educativos han identificado el nivel educativo de los padres como uno de los factores contextuales más influyentes sobre el desempeño académico estudiantil.

En conjunto, las distribuciones observadas confirman la presencia de una población altamente heterogénea desde el punto de vista socioeconómico y educativo, lo cual justifica plenamente el enfoque predictivo planteado en este estudio.

9) *Relación entre Contexto Socioeconómico y Desempeño Académico*: Con el objetivo de explorar la relación entre variables contextuales y el desempeño académico de los estudiantes, se analizó el puntaje global promedio según estrato socioeconómico y naturaleza del establecimiento educativo.

La Fig. 10 presenta las diferencias observadas entre grupos socioeconómicos y tipos de institución educativa.




Fig. 10. Puntaje global promedio según variables de contexto.

Los resultados muestran una relación positiva entre el estrato socioeconómico y el desempeño promedio en las pruebas Saber 11. Los estudiantes pertenecientes a estratos altos presentan puntajes promedio significativamente superiores frente a estudiantes de estratos bajos.

Particularmente, los estudiantes de estrato 5 y 4 obtienen promedios cercanos a 270 puntos, mientras que los estudiantes de estrato 1 presentan un promedio aproximado de 242 puntos. La categoría “Sin Estrato” registra el promedio más bajo, cercano a 213 puntos.

Esta diferencia evidencia una brecha académica sustancial asociada a condiciones socioeconómicas, lo cual coincide con hallazgos reportados en literatura de *Educational Data Mining* y estudios de desigualdad educativa.

Asimismo, se observa una diferencia importante entre instituciones oficiales y no oficiales. Los estudiantes de colegios no oficiales alcanzan un puntaje promedio aproximado de 274 puntos, mientras que los pertenecientes a instituciones oficiales presentan un promedio cercano a 244 puntos.

La diferencia observada, cercana a 30 puntos en promedio, sugiere que factores asociados al contexto institucional, disponibilidad de recursos, infraestructura educativa y condiciones socioeconómicas familiares podrían tener una influencia significativa sobre el desempeño académico.

Adicionalmente, debe considerarse que aproximadamente el 76% de los estudiantes del dataset pertenecen a instituciones



oficiales, mientras que cerca del 24% provienen de establecimientos no oficiales.

Estos resultados refuerzan la hipótesis central del presente trabajo: las variables socioeconómicas y contextuales contienen información predictiva relevante para modelar el desempeño académico estudiantil incluso en ausencia de los puntajes específicos de las pruebas.

10) *Acceso a Tecnología y Bienes del Hogar*: Con el propósito de analizar la relación entre condiciones materiales del hogar y desempeño académico, se evaluó el puntaje global promedio según distintas variables asociadas a acceso tecnológico y bienes domésticos.

Las Fig. 11 y 12 presentan los resultados obtenidos.




Fig. 11. Puntaje promedio según acceso a conectividad y tecnología.




Fig. 12. Puntaje promedio según bienes del hogar.

Los resultados muestran diferencias sustanciales en el desempeño académico asociadas al acceso a recursos tecnológicos.

Los estudiantes con acceso a internet en el hogar presentan un puntaje promedio aproximado de 261 puntos, mientras que aquellos sin acceso obtienen un promedio cercano a 228 puntos. Esta diferencia superior a 30 puntos evidencia la relevancia del acceso a conectividad digital sobre los procesos de aprendizaje y preparación académica.

De manera similar, los estudiantes cuyos hogares cuentan con computador alcanzan un promedio cercano a 266 puntos, frente a aproximadamente 234 puntos para quienes no disponen de este recurso.

Estos resultados sugieren que la disponibilidad de herramientas tecnológicas constituye un factor importante asociado al desempeño educativo, particularmente en contextos donde el acceso a contenidos digitales y recursos virtuales tiene un papel cada vez más relevante.

Asimismo, se observan diferencias importantes en variables relacionadas con bienes materiales del hogar. Los estudiantes provenientes de hogares con automóvil registran un promedio

aproximado de 270 puntos, frente a cerca de 245 puntos para quienes no poseen este bien.

En el caso de la disponibilidad de lavadora, los estudiantes cuyos hogares cuentan con este recurso presentan un promedio cercano a 256 puntos, mientras que aquellos sin acceso alcanzan aproximadamente 235 puntos.

Aunque estas variables no representan causalidad directa, sí funcionan como indicadores indirectos del nivel socioeconómico y de las condiciones materiales del entorno familiar.

En conjunto, los resultados evidencian que el acceso a tecnología y bienes domésticos mantiene una relación consistente con el desempeño académico en las pruebas Saber 11, reforzando la hipótesis de que variables contextuales y socioeconómicas contienen información predictiva relevante para la construcción de modelos de clasificación del nivel de desempeño estudiantil.

#### D. Preprocesamiento de Datos

El preprocesamiento constituye una etapa fundamental dentro del flujo de trabajo de aprendizaje de máquina, ya que permite transformar los datos crudos en un conjunto consistente y adecuado para el entrenamiento de modelos predictivos.

En esta fase se realizaron procedimientos de construcción de la variable objetivo, limpieza de registros duplicados, tratamiento de valores faltantes y preparación de variables categóricas y numéricas.

1) *Definición de la Variable Objetivo*: El objetivo del estudio consiste en predecir el nivel de desempeño académico de los estudiantes a partir de variables sociodemográficas y características del entorno educativo. Para ello, la variable continua `punt_global` fue transformada en categorías discretas de desempeño mediante dos enfoques distintos:

- 1) **Clasificación multiclase (3 categorías)**
- 2) **Clasificación binaria (2 categorías)**

La inclusión de ambos enfoques responde a hallazgos reportados en la literatura, donde múltiples estudios evidencian la dificultad de predecir desempeño académico usando únicamente variables socioeconómicas y demográficas. En particular, varios trabajos obtienen mejores resultados al simplificar el problema a una tarea binaria de clasificación.

2) *Escenario Multiclase*: En el primer enfoque, el puntaje global fue dividido en tres niveles interpretables:

TABLE V  
DEFINICIÓN DE CLASES — ESCENARIO MULTICLASE

| Nivel  | Rango Puntaje |
|--------|---------------|
| Bajo   | 0 – 225       |
| Básico | 225 – 335     |
| Alto   | 335 – 500     |

La distribución resultante se presenta en la Tabla VI.

TABLE VI  
DISTRIBUCIÓN DE CLASES — ESCENARIO MULTICLASE

| Clase  | Cantidad | %     |
|--------|----------|-------|
| Bajo   | 383,754  | 35.34 |
| Básico | 634,657  | 58.44 |
| Alto   | 67,526   | 6.22  |

Puede observarse un importante desbalance de clases, particularmente en la categoría *Alto*, que representa únicamente el 6.22% del total de observaciones.

3) *Escenario Binario*: Con el fin de evaluar si una formulación más simple del problema permitía mejorar la capacidad predictiva de los modelos, se construyó un segundo escenario de clasificación binaria.

En este caso, el puntaje global fue dividido en dos categorías:

TABLE VII  
DEFINICIÓN DE CLASES — ESCENARIO BINARIO

| Nivel | Rango Puntaje |
|-------|---------------|
| Bajo  | 0 – 250       |
| Alto  | 250 – 500     |

La distribución obtenida fue considerablemente más balanceada, como se muestra en la Tabla VIII.

TABLE VIII  
DISTRIBUCIÓN DE CLASES — ESCENARIO BINARIO

| Clase | Cantidad | %     |
|-------|----------|-------|
| Bajo  | 565,188  | 52.05 |
| Alto  | 520,749  | 47.95 |

Este segundo enfoque reduce significativamente el problema de desbalance de clases y permite evaluar la capacidad de discriminación general de los modelos entre estudiantes de desempeño relativamente bajo y alto.

La siguiente figura ilustra la distribución resultante para el caso multiclase y el escenario binario:




Fig. 13. Balance de clases - Caso multiclase




Fig. 14. Balance de clases - Caso binario

4) *Selección de Variables Predictoras*: Con el objetivo de evitar problemas de *data leakage*, se excluyeron todas

las variables de puntaje individuales y el puntaje global del conjunto de predictores utilizados para el entrenamiento de los modelos.

Asimismo, se eliminaron variables identificadoras y atributos administrativos que no aportan capacidad predictiva generalizable, tales como identificadores únicos de estudiante, códigos institucionales y nombres específicos de establecimientos educativos.

También se excluyeron variables con muy alta cardinalidad categórica debido a su impacto negativo sobre memoria computacional, dimensionalidad del espacio de características y complejidad del proceso de codificación.

Después del proceso de selección, el conjunto final de predictores quedó compuesto por 26 variables categóricas relacionadas con:

- Características del establecimiento educativo.
- Variables demográficas del estudiante.
- Condiciones socioeconómicas del hogar.
- Acceso a tecnología y bienes domésticos.

La decisión de conservar principalmente variables categóricas resulta coherente con la naturaleza del problema estudiado, dado que la mayor parte de la información contextual del dataset se encuentra representada mediante atributos discretos y ordinales.

5) *Limpieza Previa al Modelado*: Antes del entrenamiento de los modelos, se realizaron procesos de limpieza orientados a garantizar consistencia y calidad de los datos.

En primer lugar, se eliminaron registros duplicados utilizando la variable *estu\_consecutivo* como identificador único del estudiante. Dado que el análisis exploratorio confirmó que los duplicados correspondían a filas completamente idénticas, se conservó únicamente la primera ocurrencia de cada registro.

Posteriormente, se eliminaron las observaciones sin valor válido para la variable objetivo *nivel\_desempeno*, ya que dichas filas no podían ser utilizadas dentro de un esquema supervisado de clasificación.

Como resultado del proceso de limpieza, el dataset final quedó conformado por 552,841 registros únicos y válidos para modelamiento.

Finalmente, la variable objetivo categórica fue transformada mediante codificación numérica para facilitar su utilización dentro de los algoritmos de aprendizaje automático.

### E. Estrategias de Manejo de Valores Nulos

El análisis exploratorio realizado previamente evidenció la presencia de valores faltantes principalmente en variables socioeconómicas y del entorno familiar.

Dado que el patrón observado sugiere un mecanismo de ausencia no completamente aleatorio (*Missing Not At Random, MNAR*), se decidió implementar dos estrategias experimentales independientes para evaluar el impacto del tratamiento de nulos sobre el desempeño predictivo de los modelos.

1) *Experimento 1: Eliminación de Valores Nulos*: En el primer experimento, se eliminaron todas las observaciones que contenían al menos un valor faltante dentro de las variables predictoras.

Esta estrategia permite trabajar exclusivamente con registros completamente observados, evitando introducir sesgos potenciales derivados de la imputación artificial de variables socioeconómicas sensibles.

A pesar de la reducción del tamaño del dataset, la cantidad restante de observaciones continuó siendo suficientemente grande para garantizar robustez estadística durante el entrenamiento y evaluación de los modelos.

2) *Experimento 2: Imputación de Valores Faltantes*: En el segundo experimento, se implementó una estrategia de imputación para conservar la mayor cantidad posible de registros disponibles.

Las variables numéricas fueron imputadas utilizando la mediana debido a su robustez frente a valores atípicos, mientras que las variables categóricas fueron completadas mediante la moda correspondiente.

Esta estrategia permite incrementar el volumen de datos utilizados durante el entrenamiento y evaluar si la retención de observaciones mejora la capacidad de generalización de los modelos predictivos.

#### F. División Train/Test

Para ambos experimentos, el dataset fue dividido utilizando una estrategia *Train/Test Split* estratificada, preservando la proporción original de las clases de la variable objetivo.

Se utilizó una partición de 80% para entrenamiento y 20% para prueba.

La estratificación resulta especialmente importante debido al desbalance moderado presente en la clase correspondiente al nivel de desempeño alto.

Como resultado:

- Experimento 1 (sin imputación):
  - Train: 325,158 registros
  - Test: 81,290 registros
- Experimento 2 (con imputación):
  - Train: 442,272 registros
  - Test: 110,569 registros

#### G. Pipelines de Preprocesamiento

Con el fin de garantizar reproducibilidad y evitar fuga de información durante el entrenamiento, se construyeron *pipelines* de preprocesamiento independientes para cada experimento.

En ambos casos, las variables categóricas fueron transformadas mediante técnicas de codificación apropiadas para algoritmos de aprendizaje automático.

Para el experimento sin imputación, el pipeline incluyó procesos de escalamiento y codificación categórica.

En el experimento con imputación, se añadieron adicionalmente etapas de imputación para variables numéricas y categóricas antes de la transformación final de los datos.

El uso de pipelines permite encapsular todas las transformaciones dentro de un flujo consistente y reproducible, reduciendo riesgos de contaminación entre conjuntos de entrenamiento y prueba.

### III. EXPERIMENTOS

#### A. Regresión logística — Experimentos multi-clase

Como línea base interpretable para la tarea de clasificación, se evaluó un modelo de regresión logística multinomial. Este modelo fue seleccionado debido a su amplia utilización en problemas de clasificación supervisada, su bajo costo computacional y la facilidad para interpretar la contribución de las variables predictoras.

Con el fin de optimizar el desempeño del modelo, se realizó una búsqueda exhaustiva de hiperparámetros mediante *Grid Search* con validación cruzada estratificada de cinco particiones (*Stratified K-Fold*). Se exploraron diferentes configuraciones del parámetro de regularización (C), el uso de balanceo de clases (*class\_weight*) y los algoritmos de optimización (*solvers*).

El espacio de búsqueda considerado fue el siguiente:

- $C \in \{0.01, 0.1, 1, 10, 100\}$
- *class\_weight* ( $\in$  None, balanced)
- *solver* ( $\in$  lbfgs, newton-cg)

Adicionalmente, el modelo fue evaluado bajo dos estrategias de tratamiento de valores faltantes: eliminación de registros incompletos e imputación de valores. En ambos casos, la mejor configuración encontrada correspondió a:

- (C = 100)
- *solver* = lbfgs
- *class\_weight* = None

Los resultados obtenidos fueron prácticamente idénticos para ambas estrategias de preprocesamiento, alcanzando una *accuracy* de 0.6691, un *F1-score macro* de 0.4938 y un valor de *ROC-AUC* de 0.7595.




Fig. 15. Matriz de confusión — Mejor modelo caso eliminación.




Fig. 16. Matriz de confusión — Mejor modelo caso imputación.



Aunque la regresión logística presentó una capacidad de discriminación razonable, evidenciada por el valor de ROC-AUC, el análisis detallado de las métricas por clase muestra dificultades para identificar adecuadamente la categoría de menor frecuencia. En particular, la clase correspondiente al nivel de desempeño más bajo obtuvo un *recall* considerablemente inferior al observado en las demás categorías, lo que redujo el valor global de F1-score macro.

No obstante, los resultados obtenidos permiten establecer una línea base sólida para el problema de clasificación multiclase. El modelo logró capturar una parte importante de la relación existente entre las variables sociodemográficas y el desempeño académico, alcanzando niveles aceptables de precisión global y capacidad de discriminación. Sin embargo, las diferencias observadas entre las métricas de las distintas clases sugieren que el problema presenta un grado de complejidad adicional que podría requerir modelos capaces de representar relaciones más complejas entre las variables predictoras.

En consecuencia, la configuración seleccionada para la regresión logística multinomial corresponde a aquella obtenida mediante *Grid Search*, con ( $C=100$ ), *solver=lbfgs* y sin balanceo de clases, la cual alcanzó los mejores resultados globales dentro de las configuraciones evaluadas.

### B. Regresión logística — Clasificación binaria

Una vez identificado el mejor esquema de hiperparámetros para la regresión logística, se evaluó el modelo en el escenario de clasificación binaria. Al igual que en el caso multiclase, se consideraron tanto la eliminación de registros incompletos como la imputación de valores faltantes, obteniéndose resultados equivalentes en ambas configuraciones.

La mejor combinación de hiperparámetros correspondió a:

- ( $C = 100$ )
- *solver* = lbfgs
- *class\_weight* = balanced

Bajo esta configuración, el modelo alcanzó una *accuracy* de 0.6921, un *F1-score macro* de 0.6919 y un valor de ROC-AUC de 0.7641. Adicionalmente, las métricas de precisión y sensibilidad mostraron valores prácticamente idénticos para ambas clases, lo que indica un comportamiento equilibrado y ausencia de sesgos significativos hacia alguna categoría específica.




Fig. 17. Matriz de confusión — Mejor modelo caso eliminación.




Fig. 18. Matriz de confusión — Mejor modelo caso imputación.

Los resultados obtenidos evidencian una mejora sustancial respecto al escenario multiclase. Esto era esperable, dado que la reducción del problema a dos categorías simplifica las fronteras de decisión y facilita la identificación de patrones relevantes en los datos sociodemográficos.

El comportamiento equilibrado observado entre precisión y sensibilidad indica que el modelo mantiene un desempeño homogéneo sobre ambas clases, evitando sesgos significativos hacia alguna de ellas. Asimismo, el valor de ROC-AUC obtenido demuestra una adecuada capacidad de discriminación entre estudiantes pertenecientes a las dos categorías consideradas.

En términos generales, los resultados muestran que la regresión logística constituye una alternativa efectiva para la predicción binaria del desempeño académico, proporcionando un equilibrio adecuado entre capacidad predictiva, simplicidad computacional e interpretabilidad. Por esta razón, la configuración obtenida mediante *Grid Search*, con ( $C=100$ ), *solver=lbfgs* y balanceo de clases activado, se selecciona como el modelo final para el escenario de clasificación binaria dentro de la familia de modelos de regresión logística.

### C. Random Forest — Escenario Multiclase

1) *Experimento 1 — Eliminación de Nulos*: El primer modelo entrenado corresponde a un clasificador *Random Forest* utilizando el conjunto de datos del Experimento 1, donde todas las observaciones con valores faltantes fueron eliminadas previamente.

El modelo fue configurado utilizando 300 árboles de decisión, profundidad máxima de 15 niveles y ponderación balanceada de clases (*class\_weight='balanced'*) con el fin de mitigar el efecto del desbalance presente en la variable objetivo.

La Tabla IX resume las métricas de desempeño obtenidas sobre el conjunto de prueba.

TABLE IX  
RESULTADOS GLOBALES — RANDOM FOREST (EXPERIMENTO 1)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.5191 |
| F1-score (macro)    | 0.4824 |
| F1-score (weighted) | 0.5276 |
| Precision (macro)   | 0.4835 |
| Recall (macro)      | 0.5921 |
| ROC-AUC (OvR macro) | 0.7403 |

Los resultados muestran un desempeño moderado del modelo, con una capacidad razonable para distinguir entre las tres clases de desempeño académico.

El valor de ROC-AUC macro de 0.7403 sugiere que el modelo logra capturar patrones discriminativos relevantes entre las categorías, aunque todavía presenta dificultades importantes asociadas al desbalance de clases y al solapamiento entre niveles de desempeño intermedios.

La Tabla X presenta las métricas detalladas por clase.

TABLE X  
REPORTE DE CLASIFICACIÓN — RANDOM FOREST (EXPERIMENTO 1)

| Clase        | Precision | Recall | F1-score | Support |
|--------------|-----------|--------|----------|---------|
| Bajo         | 0.50      | 0.69   | 0.58     | 26,071  |
| Básico       | 0.72      | 0.41   | 0.52     | 49,326  |
| Alto         | 0.23      | 0.68   | 0.34     | 5,893   |
| Macro Avg    | 0.48      | 0.59   | 0.48     | 81,290  |
| Weighted Avg | 0.61      | 0.52   | 0.53     | 81,290  |

Se observa que el modelo logra un *recall* elevado para las clases *Bajo* y *Alto*, lo cual indica buena sensibilidad para detectar estudiantes en los extremos del desempeño académico.

Sin embargo, la precisión de la clase *Alto* resulta considerablemente baja (0.23), evidenciando una alta tasa de falsos positivos. Esto sugiere que el modelo tiende a sobrepredecir estudiantes con desempeño alto como consecuencia del balanceo de clases aplicado durante el entrenamiento.

Por otro lado, la clase *Básico* presenta la mayor precisión (0.72), aunque con un *recall* relativamente bajo (0.41), indicando dificultades para recuperar correctamente todos los estudiantes pertenecientes a esta categoría intermedia.

La Figura 19 presenta la matriz de confusión correspondiente al modelo Random Forest del Experimento 1.




Fig. 19. Matriz de confusión — Random Forest (Experimento 1)

La matriz de confusión evidencia que la principal fuente de error ocurre entre las clases *Bajo* y *Básico*, lo cual resulta consistente con el solapamiento natural existente entre estudiantes cercanos a los umbrales de categorización definidos para el puntaje global.

Asimismo, el modelo presenta una tendencia importante a clasificar estudiantes de la clase *Básico* como *Alto*, generando un número considerable de falsos positivos en la categoría minoritaria.

A pesar de estas limitaciones, el modelo demuestra capacidad para capturar patrones socioeconómicos relevantes asociados al desempeño académico, incluso sin utilizar variables de puntaje individuales.

2) *Experimento 2 — Imputación de Nulos*: El segundo experimento empleó la estrategia de imputación de valores faltantes antes del entrenamiento del modelo. Las variables categóricas fueron imputadas utilizando la moda y posteriormente codificadas mediante *OneHotEncoder*. Sobre este pipeline se entrenó un clasificador *Random Forest* con los mismos hiperparámetros utilizados en el Experimento 1: 300 árboles, profundidad máxima de 15 y balanceo de clases mediante `class_weight='balanced'`.

Los resultados obtenidos se muestran en la Tabla XI.

TABLE XI  
RESULTADOS RANDOM FOREST — EXPERIMENTO 2 (IMPUTACIÓN)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.5369 |
| F1-score (macro)    | 0.4917 |
| F1-score (weighted) | 0.5474 |
| Precision (macro)   | 0.4924 |
| Recall (macro)      | 0.6022 |
| ROC-AUC (OvR macro) | 0.7492 |

Comparado con el experimento basado en eliminación de nulos, el modelo presentó una mejora moderada en todas las métricas principales. El *accuracy* aumentó de 51.9% a 53.7%, mientras que el ROC-AUC pasó de 0.7403 a 0.7492, indicando una mejor capacidad discriminativa al conservar una mayor cantidad de registros mediante imputación.

La Tabla XII presenta el desempeño detallado por clase.

TABLE XII  
REPORTE DE CLASIFICACIÓN — RF EXPERIMENTO 2

| Clase        | Precision | Recall | F1-score | Soporte |
|--------------|-----------|--------|----------|---------|
| Bajo         | 0.55      | 0.70   | 0.61     | 38,800  |
| Básico       | 0.71      | 0.42   | 0.53     | 64,529  |
| Alto         | 0.22      | 0.69   | 0.33     | 7,240   |
| Macro Avg    | 0.49      | 0.60   | 0.49     | 110,569 |
| Weighted Avg | 0.62      | 0.54   | 0.55     | 110,569 |

Los resultados evidencian nuevamente un comportamiento desbalanceado del modelo: la clase *Alto* mantiene un *recall* elevado (0.69), pero con una precisión muy baja (0.22), lo que indica una alta tasa de falsos positivos. Esto sugiere que el modelo tiende a sobreestimar estudiantes de alto desempeño debido al balanceo interno de clases.

Asimismo, la clase *Básico*, que corresponde a la categoría mayoritaria, continúa siendo la más difícil de separar correctamente, presentando un *recall* relativamente bajo (0.42). Esto refleja un importante solapamiento entre los perfiles socioeconómicos asociados a las clases *Bajo* y *Básico*.

La matriz de confusión correspondiente se presenta en la Figura 20.




Fig. 20. Matriz de confusión — Random Forest Experimento 2 (Imputación).

La matriz confirma que gran parte de los errores ocurre entre las clases *Bajo* y *Básico*, las cuales presentan características socioeconómicas parcialmente similares. Sin embargo, el modelo logra identificar correctamente una proporción considerable de estudiantes pertenecientes a la clase *Alto*, aun cuando esta representa únicamente el 6.2% del conjunto de datos.

En términos generales, los resultados sugieren que la estrategia de imputación permite aprovechar una mayor cantidad de información disponible y mejora ligeramente la capacidad predictiva del modelo frente a la eliminación directa de registros con valores faltantes.

#### D. Random Forest — Escenario de Clasificación Binaria

Dado el desempeño limitado obtenido en el escenario multiclase, se realizó una segunda serie de experimentos reformulando el problema como una tarea de clasificación binaria.

La motivación principal fue reducir la complejidad del espacio de decisión y disminuir el impacto del desbalance de clases observado en la categoría *Alto* del escenario multiclase.

1) *Experimento 1 — Eliminación de Nulos*: El primer experimento binario utilizó la estrategia de eliminación de registros con valores faltantes antes del entrenamiento.

Los resultados obtenidos se presentan en la Tabla XIII.

TABLE XIII  
RESULTADOS RF — EXPERIMENTO 3 (BINARIO + ELIMINACIÓN)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.6844 |
| F1-score (macro)    | 0.6844 |
| F1-score (weighted) | 0.6845 |
| Precision (macro)   | 0.6846 |
| Recall (macro)      | 0.6847 |

Los resultados muestran una mejora sustancial frente al escenario multiclase. El *accuracy* aumentó de aproximadamente 52% a 68.4%, confirmando que la reducción del número de categorías facilita significativamente la tarea de clasificación.

TABLE XIV  
REPORTE DE CLASIFICACIÓN — RF EXPERIMENTO 3

| Clase | Precision | Recall | F1-score | Soporte |
|-------|-----------|--------|----------|---------|
| Bajo  | 0.67      | 0.69   | 0.68     | 39,640  |
| Alto  | 0.70      | 0.68   | 0.69     | 41,650  |

A diferencia del escenario multiclase, el modelo presenta un desempeño mucho más equilibrado entre ambas clases, sin evidencia de sesgo fuerte hacia una categoría específica.




Fig. 21. Matriz de confusión — RF Experimento 3.

La matriz de confusión muestra que el modelo logra separar de manera relativamente estable los estudiantes de bajo y alto desempeño, aunque todavía existe una proporción importante de confusión entre ambas categorías.

2) *Experimento 2 — Imputación de Nulos*: El cuarto experimento mantuvo el enfoque binario, pero utilizando imputación de valores faltantes.

Los resultados obtenidos se muestran en la Tabla XV.

TABLE XV  
RESULTADOS RF — EXPERIMENTO 4 (BINARIO + IMPUTACIÓN)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.6882 |
| F1-score (macro)    | 0.6879 |
| F1-score (weighted) | 0.6883 |
| Precision (macro)   | 0.6879 |
| Recall (macro)      | 0.6879 |

El uso de imputación permitió una mejora marginal respecto al experimento anterior, alcanzando un *accuracy* cercano al 69%.

TABLE XVI  
REPORTE DE CLASIFICACIÓN — RF EXPERIMENTO 4

| Clase | Precision | Recall | F1-score | Soporte |
|-------|-----------|--------|----------|---------|
| Bajo  | 0.70      | 0.70   | 0.70     | 57,144  |
| Alto  | 0.68      | 0.68   | 0.68     | 53,425  |

Los resultados evidencian nuevamente un comportamiento balanceado entre ambas clases, con métricas prácticamente simétricas.




Fig. 22. Matriz de confusión — RF Experimento 4.

En términos generales, el escenario binario permitió obtener mejoras importantes en todas las métricas respecto al enfoque multiclase. Esto coincide con observaciones reportadas en trabajos previos, donde la predicción de desempeño académico basada únicamente en variables socioeconómicas tiende a presentar límites de separabilidad entre categorías intermedias.

Los resultados sugieren que las variables contextuales utilizadas poseen mayor capacidad para discriminar entre estudiantes de desempeño relativamente alto y bajo, pero presentan dificultades para modelar niveles intermedios de desempeño académico.

#### E. XGBoost — Escenario Multiclase

Con el objetivo de comparar el desempeño de modelos basados en ensamblaje, se entrenó un clasificador *XGBoost* bajo las mismas configuraciones experimentales utilizadas previamente con Random Forest.

XGBoost fue seleccionado debido a su capacidad para modelar relaciones no lineales, manejar grandes volúmenes de datos y optimizar funciones de pérdida mediante *gradient boosting*, lo cual lo convierte en una de las técnicas más utilizadas en problemas tabulares de clasificación supervisada.

1) *Experimento 1 — Eliminación de Nulos*: En el primer experimento se eliminaron los registros con valores faltantes antes del entrenamiento.

Los resultados obtenidos se presentan en la Tabla XVII.

TABLE XVII  
RESULTADOS XGBOOST — EXPERIMENTO 1 (MULTICLASE + ELIMINACIÓN)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.6783 |
| F1-score (macro)    | 0.5103 |
| F1-score (weighted) | 0.6504 |
| Precision (macro)   | 0.6458 |
| Recall (macro)      | 0.4849 |
| ROC-AUC (OvR macro) | 0.7723 |

A diferencia de Random Forest, XGBoost presentó una mejora considerable en el desempeño general del problema multiclase, alcanzando un *accuracy* cercano al 68%.

Sin embargo, el análisis por clase evidencia un comportamiento desigual, como se muestra en la Tabla XVIII.

TABLE XVIII  
REPORTE DE CLASIFICACIÓN — XGBOOST EXPERIMENTO 1

| Clase        | Precision | Recall | F1-score | Soporte |
|--------------|-----------|--------|----------|---------|
| Bajo         | 0.66      | 0.43   | 0.52     | 26,071  |
| Básico       | 0.69      | 0.87   | 0.77     | 49,326  |
| Alto         | 0.59      | 0.15   | 0.24     | 5,893   |
| Macro Avg    | 0.65      | 0.48   | 0.51     | 81,290  |
| Weighted Avg | 0.67      | 0.68   | 0.65     | 81,290  |

El modelo presenta un desempeño particularmente fuerte en la clase *Básico*, alcanzando un *recall* de 0.87 y un F1-score de 0.77. Esto indica que XGBoost tiende a concentrar gran parte de las predicciones sobre la categoría intermedia, favoreciendo la clase mayoritaria del dataset.

Por otro lado, la clase *Alto* continúa siendo la más difícil de identificar, con un *recall* de apenas 0.15. Aunque la precisión para esta categoría alcanza 0.59, el modelo logra detectar correctamente solo una pequeña fracción de los estudiantes realmente pertenecientes a dicha clase.

La matriz de confusión correspondiente se muestra en la Figura 23.




Fig. 23. Matriz de confusión — XGBoost Experimento 1.

La matriz evidencia que la mayoría de errores se concentran entre las clases *Bajo* y *Básico*, mientras que gran parte de los casos reales de la clase *Alto* son clasificados incorrectamente como *Básico*.

2) *Experimento 2 — Imputación de Nulos*: El segundo experimento incorporó imputación de valores faltantes previo al entrenamiento del modelo.

Los resultados se presentan en la Tabla XIX.

TABLE XIX  
RESULTADOS XGBOOST — EXPERIMENTO 2 (MULTICLASE + IMPUTACIÓN)

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.6809 |
| F1-score (macro)    | 0.5194 |
| F1-score (weighted) | 0.6591 |
| Precision (macro)   | 0.6515 |
| Recall (macro)      | 0.4962 |
| ROC-AUC (OvR macro) | 0.7865 |

La estrategia de imputación produjo mejoras leves pero consistentes en prácticamente todas las métricas respecto al

experimento anterior. El ROC-AUC alcanzó 0.7865, constituyendo el mejor resultado obtenido hasta este punto para el escenario multiclase.

La Tabla XX presenta el desempeño detallado por clase.

TABLE XX  
REPORTE DE CLASIFICACIÓN — XGBOOST EXPERIMENTO 2

| Clase        | Precision | Recall | F1-score | Soporte |
|--------------|-----------|--------|----------|---------|
| Bajo         | 0.68      | 0.50   | 0.58     | 38,800  |
| Básico       | 0.68      | 0.85   | 0.76     | 64,529  |
| Alto         | 0.59      | 0.14   | 0.22     | 7,240   |
| Macro Avg    | 0.65      | 0.50   | 0.52     | 110,569 |
| Weighted Avg | 0.68      | 0.68   | 0.66     | 110,569 |

Los resultados mantienen el mismo patrón observado previamente: el modelo logra una alta capacidad predictiva sobre la clase *Básico*, pero presenta dificultades importantes para identificar estudiantes de alto desempeño.

A pesar de ello, el modelo supera ampliamente los resultados obtenidos por Random Forest en el escenario multiclase, particularmente en términos de accuracy, ROC-AUC y estabilidad general.




Fig. 24. Matriz de confusión — XGBoost Experimento 2.

La matriz de confusión confirma nuevamente que la mayor dificultad del problema radica en distinguir correctamente la clase *Alto*, debido a su baja representación relativa y al solapamiento de características socioeconómicas con la categoría *Básico*.

En términos generales, XGBoost demostró una capacidad de generalización considerablemente superior a Random Forest en el escenario multiclase, aunque el problema de desbalance y separabilidad entre clases continúa siendo un desafío importante para el modelo.

#### F. XGBoost — Escenario de Clasificación Binaria

Dado el bajo desempeño observado en el escenario multiclase, se planteó un segundo enfoque basado en clasificación binaria, agrupando los estudiantes en únicamente dos categorías de desempeño:

- **Bajo:** puntaje global entre 0 y 250.
- **Alto:** puntaje global entre 250 y 500.

La motivación de este experimento surge del análisis del estado del arte, donde diversos estudios reportan dificultades

significativas para clasificar múltiples niveles de desempeño académico utilizando exclusivamente variables sociodemográficas y contextuales. En consecuencia, numerosos trabajos reducen el problema a dos categorías para obtener modelos con mayor capacidad predictiva.

a) *Experimento 1 — Eliminación de nulos:* En este escenario se utilizó la estrategia de eliminación completa de registros con valores faltantes antes del entrenamiento del modelo.

Los resultados obtenidos se presentan en la Tabla XXI.

TABLE XXI  
RESULTADOS XGBOOST BINARIO — ELIMINACIÓN DE NULOS

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.7049 |
| F1-score (macro)    | 0.7043 |
| F1-score (weighted) | 0.7047 |
| Precision (macro)   | 0.7049 |
| Recall (macro)      | 0.7042 |
| ROC-AUC             | 0.7798 |

La matriz de confusión correspondiente se muestra en la Figura 28.




Fig. 25. Matriz de confusión — XGBoost binario con eliminación de nulos.

TABLE XXII  
MATRIZ DE CONFUSIÓN TEXTUAL — XGBOOST BINARIO (ELIMINACIÓN)

|           | Pred Bajo | Pred Alto |
|-----------|-----------|-----------|
| Real Bajo | 26,873    | 12,767    |
| Real Alto | 11,222    | 30,428    |

Los resultados evidencian una mejora sustancial frente al escenario multiclase. El modelo alcanzó un accuracy superior al 70%, junto con métricas balanceadas de precisión y recall para ambas clases.

A diferencia de los experimentos multiclase, donde el modelo tendía a concentrar las predicciones en la categoría intermedia, el enfoque binario permitió una separación más estable entre estudiantes de desempeño bajo y alto. La matriz de confusión muestra además un comportamiento relativamente equilibrado en ambas clases, sin un sesgo extremo hacia una categoría dominante.

El valor ROC-AUC de 0.7798 sugiere que el modelo logra una capacidad discriminativa adecuada utilizando únicamente variables sociodemográficas, familiares y contextuales.



b) *Experimento 2 — Imputación de nulos*: En el segundo escenario se aplicó imputación de valores faltantes antes del entrenamiento, utilizando mediana para variables numéricas y moda para variables categóricas. Esta estrategia permitió conservar una mayor cantidad de registros durante el proceso de entrenamiento.

Los resultados obtenidos se presentan en la Tabla XXIII.

TABLE XXIII  
RESULTADOS XGBOOST BINARIO — IMPUTACIÓN

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.7085 |
| F1-score (macro)    | 0.7081 |
| F1-score (weighted) | 0.7084 |
| Precision (macro)   | 0.7081 |
| Recall (macro)      | 0.7080 |
| ROC-AUC             | 0.7865 |

La matriz de confusión correspondiente se muestra en la Figura 26.




Fig. 26. Matriz de confusión — XGBoost binario con imputación de nulos.

TABLE XXIV  
MATRIZ DE CONFUSIÓN TEXTUAL — XGBOOST BINARIO (IMPUTACIÓN)

|           | Pred Bajo | Pred Alto |
|-----------|-----------|-----------|
| Real Bajo | 41,211    | 15,933    |
| Real Alto | 16,302    | 37,123    |

Los resultados muestran una ligera mejora respecto al escenario de eliminación de nulos. El modelo alcanzó un accuracy de 70.85% y un ROC-AUC de 0.7865, constituyendo el mejor desempeño obtenido dentro de todos los experimentos realizados con variables sociodemográficas y contextuales.

A diferencia del enfoque multiclase, donde las métricas presentaban una fuerte degradación debido al desbalance y la complejidad de separación entre categorías intermedias, el esquema binario permitió una frontera de decisión más estable y consistente.

Las métricas de precisión, recall y F1-score fueron altamente balanceadas entre ambas clases, evidenciando que el modelo no presenta un sesgo dominante hacia una única categoría. De manera similar, la matriz de confusión refleja una distribución relativamente homogénea de errores entre estudiantes clasificados como “Bajo” y “Alto”.

El incremento observado en el desempeño del modelo bajo imputación sugiere que conservar registros parcialmente incompletos aporta información relevante al proceso de aprendizaje, especialmente en variables socioeconómicas y familiares donde la ausencia de información podría contener patrones implícitos asociados al desempeño académico.

Finalmente, aunque los resultados obtenidos no alcanzan niveles típicos de problemas de clasificación estructurada altamente separables, sí son consistentes con lo reportado en la literatura para escenarios de predicción académica basados únicamente en variables sociodemográficas. En este contexto, obtener valores cercanos al 71% de accuracy y 0.79 de ROC-AUC representa un resultado competitivo y metodológicamente sólido.

### G. Red neuronal — Experimentos multi-clase

Las redes neuronales artificiales presentan una gran flexibilidad para modelar relaciones no lineales entre las variables de entrada y la variable objetivo. Sin embargo, su desempeño depende en gran medida de la arquitectura seleccionada, por lo que fue necesario realizar una serie de experimentos orientados a identificar la configuración más adecuada para la tarea de clasificación del desempeño académico en las pruebas Saber 11.

Con el fin de evaluar el efecto de la profundidad y la distribución de neuronas en las capas ocultas, se diseñaron tres arquitecturas diferentes:

- **Expansión de dimensiones**: 1024 – 512 – 256 neuronas (Experimento 1).
- **Reducción progresiva de dimensiones**: 128 – 64 – 32 neuronas (Experimento 2).
- **Expansión y posterior reducción**: 512 – 1024 – 64 neuronas (Experimento 3).

En todos los casos, la capa de entrada estuvo determinada por el número de variables disponibles después del proceso de preprocesamiento, mientras que la capa de salida estuvo compuesta por tres neuronas con función de activación *softmax*, correspondientes a las categorías de desempeño académico *Bajo*, *Medio* y *Alto*.

Adicionalmente, cada arquitectura fue evaluada bajo dos estrategias de tratamiento de valores faltantes: *eliminación de registros incompletos* e *imputación de valores*. Como resultado, se obtuvieron seis configuraciones experimentales diferentes para el escenario de clasificación multiclase.

La Figura 28 presenta un resumen de las métricas obtenidas para cada una de las configuraciones evaluadas.




Fig. 27. Comparación de resultados para las diferentes arquitecturas de red neuronal evaluadas en el escenario multiclase.

A partir de los resultados obtenidos, se seleccionó como modelo final para la clasificación multiclase la configuración correspondiente al **Experimento 1 con imputación de valores**. Esta variante alcanzó el mejor equilibrio global entre las métricas de evaluación, obteniendo una *accuracy* de 0.6017 y el mayor *F1-score macro* (0.5214), indicador especialmente relevante en problemas multiclase debido a que evalúa el desempeño promedio sobre todas las categorías sin favorecer a las clases más frecuentes.

Asimismo, el modelo obtuvo un valor de *ROC-AUC* de 0.7379, lo que evidencia una adecuada capacidad de discriminación entre los diferentes niveles de desempeño académico. El balance observado entre precisión y sensibilidad sugiere que la red neuronal es capaz de identificar correctamente estudiantes pertenecientes a distintas categorías de rendimiento sin incurrir en un sesgo excesivo hacia una clase particular.

En conjunto, estos resultados muestran que la arquitectura basada en expansión progresiva de dimensiones permite capturar de manera más efectiva las relaciones existentes entre los factores sociodemográficos y el desempeño académico, constituyéndose como la alternativa más robusta para el escenario de clasificación multiclase.

#### H. Red neuronal — Clase binaria

Para este escenario se tomo la estructura ganadora del caso multi-clase y se uso para la predicción del caso binario, y estos fueron los resultados:




Fig. 28. Matriz de confusión caso clasificación binaria.

TABLE XXV  
RESULTADOS DE EVALUACIÓN DEL MODELO

| Métrica             | Valor  |
|---------------------|--------|
| Accuracy            | 0.6995 |
| F1-score (Macro)    | 0.6991 |
| F1-score (Weighted) | 0.6995 |
| Precision (Macro)   | 0.6992 |
| Recall (Macro)      | 0.6991 |
| ROC-AUC             | 0.7767 |

Los resultados obtenidos en el escenario binario muestran una mejora sustancial respecto al problema multiclase. El modelo alcanzó una *accuracy* de 0.6995 y un *F1-score macro* de 0.6991, evidenciando una capacidad de clasificación considerablemente superior cuando el problema se reduce a dos categorías. De igual manera, el valor de *ROC-AUC* de 0.7767

indica una adecuada capacidad de discriminación entre las clases consideradas.

Este comportamiento era esperable, dado que la simplificación del espacio de decisión reduce la complejidad del problema y permite que la red neuronal identifique con mayor facilidad los patrones asociados al desempeño académico. Los resultados obtenidos sugieren que los factores sociodemográficos incluidos en el estudio contienen información suficiente para distinguir de forma razonablemente precisa entre estudiantes con desempeño favorable y desfavorable, aunque presentan mayores dificultades para separar categorías intermedias cuando se aborda el problema multiclase.

#### IV. RESULTADOS Y DISCUSIÓN

Se evaluaron cuatro algoritmos de aprendizaje supervisado para la predicción del desempeño académico a partir de variables sociodemográficas: Regresión Logística (RL), Random Forest (RF), XGBoost (XGB) y Redes Neuronales Artificiales (RN).

Los experimentos fueron desarrollados bajo dos configuraciones de clasificación:

- **Clasificación multiclase:** Bajo, Básico y Alto.
- **Clasificación binaria:** Bajo y Alto.

Adicionalmente, se analizaron dos estrategias de tratamiento de valores faltantes:

- Eliminación de registros incompletos.
- Imputación de valores faltantes.

Dado que la distribución de clases presenta desbalance, especialmente en el escenario multiclase, el criterio principal de comparación corresponde al **F1-score Macro**, ya que evalúa el desempeño promedio sobre todas las clases sin verse influenciado por la frecuencia de cada una.

#### A. Resultados en Clasificación Multiclase

La Tabla XXVI resume los mejores resultados obtenidos para cada modelo en el escenario de tres categorías.

TABLE XXVI  
COMPARACIÓN DE MODELOS EN CLASIFICACIÓN MULTICLASE

| Modelo                     | Accuracy | Precision | Recall | F1 Macro      | F1 Weighted | ROC-AUC |
|----------------------------|----------|-----------|--------|---------------|-------------|---------|
| Regresión Logística        | 0.6691   | 0.6362    | 0.4713 | 0.4938        | 0.6382      | 0.7595  |
| Random Forest (Imputación) | 0.5369   | 0.4924    | 0.6022 | 0.4917        | 0.5474      | 0.7492  |
| XGBoost (Imputación)       | 0.6809   | 0.6515    | 0.4962 | 0.5194        | 0.6591      | 0.7865  |
| Red Neuronal               | 0.6017   | 0.5084    | 0.5473 | <b>0.5214</b> | 0.6086      | 0.7379  |

Los resultados evidencian que XGBoost alcanzó la mayor exactitud global (*Accuracy* = 68.09%) y el mayor valor de *ROC-AUC* (78.65%), lo que indica una elevada capacidad de discriminación entre categorías.

Sin embargo, al utilizar el *F1-score Macro* como criterio principal de evaluación, la mejor configuración corresponde a la Red Neuronal Artificial, con un valor de **0.5214**. Este resultado sugiere que la red neuronal distribuye de manera más equilibrada su capacidad predictiva entre las tres categorías de desempeño académico.

La Regresión Logística obtuvo una *accuracy* competitiva (66.91%), pero presentó una reducción importante en *Recall*

Macro (47.13%), evidenciando dificultades para identificar adecuadamente las clases minoritarias.

Por su parte, Random Forest obtuvo los resultados más discretos del conjunto de modelos evaluados. Aunque logró un Recall Macro relativamente elevado (60.22%), su precisión fue considerablemente menor, produciendo una gran cantidad de falsos positivos y afectando negativamente el F1-score Macro.

En términos generales, los resultados muestran que la clasificación multiclase constituye un problema complejo debido a la dificultad para diferenciar adecuadamente los tres niveles de desempeño utilizando únicamente variables sociodemográficas.

### B. Resultados en Clasificación Binaria

Debido a las dificultades observadas en el escenario multiclase, se planteó una segunda formulación del problema basada únicamente en dos categorías de desempeño académico.

La Tabla XXVII presenta los mejores resultados obtenidos para cada modelo.

TABLE XXVII  
COMPARACIÓN DE MODELOS EN CLASIFICACIÓN BINARIA

| Modelo                     | Accuracy      | Precision     | Recall        | F1 Macro      | F1 Weighted   | ROC-AUC       |
|----------------------------|---------------|---------------|---------------|---------------|---------------|---------------|
| Regresión Logística        | 0.6921        | 0.6919        | 0.6919        | 0.6919        | 0.6921        | 0.7641        |
| Random Forest (Imputación) | 0.6882        | 0.6879        | 0.6879        | 0.6879        | 0.6883        | 0.7629        |
| XGBoost (Imputación)       | <b>0.7085</b> | <b>0.7081</b> | <b>0.7080</b> | <b>0.7081</b> | <b>0.7084</b> | <b>0.7865</b> |
| Red Neuronal               | 0.6995        | 0.6992        | 0.6991        | 0.6991        | 0.6995        | 0.7767        |

La simplificación del problema produjo una mejora significativa en todos los modelos evaluados.

XGBoost obtuvo el mejor desempeño global, alcanzando un Accuracy de 70.85%, un F1-score Macro de 70.81% y un ROC-AUC de 78.65%.

Con el fin de interpretar el comportamiento del modelo seleccionado, se analizó la importancia de las variables utilizadas por XGBoost. Los resultados evidenciaron que la disponibilidad de computador e internet en el hogar, la jornada académica de la institución educativa, el departamento de residencia del estudiante y el nivel educativo de los padres constituyen algunos de los factores con mayor influencia sobre las predicciones realizadas.

Este hallazgo coincide con numerosos estudios previos que señalan la relación existente entre las condiciones socioeconómicas, el acceso a recursos tecnológicos y el desempeño académico de los estudiantes en pruebas estandarizadas.

Las Redes Neuronales ocuparon el segundo lugar, con un F1-score Macro de 69.91%, seguidas muy de cerca por la Regresión Logística (69.19%) y Random Forest (68.79%).

Un aspecto relevante es que las diferencias entre modelos se reducen considerablemente respecto al escenario multiclase. Esto sugiere que gran parte de la información predictiva contenida en las variables sociodemográficas es suficiente para distinguir entre estudiantes de bajo y alto desempeño, pero resulta insuficiente para separar con precisión múltiples niveles intermedios de rendimiento.

### C. Impacto del Tratamiento de Valores Faltantes

En todos los modelos evaluados se observó una ligera mejora cuando se utilizó imputación en lugar de eliminación de registros incompletos.

Las diferencias fueron relativamente pequeñas, generalmente inferiores a dos puntos porcentuales en Accuracy y F1-score Macro.

Este comportamiento indica que la información contenida en los registros eliminados no altera significativamente los patrones de aprendizaje o que la estrategia de imputación utilizada logra preservar adecuadamente la estructura estadística de los datos originales.

Dado que la imputación permite conservar una cantidad considerablemente mayor de observaciones para entrenamiento, puede considerarse la estrategia más conveniente para este conjunto de datos.

### D. Comparación de Desempeño Computacional

Además de las métricas predictivas, se analizaron los tiempos de entrenamiento promedio observados durante los experimentos.

TABLE XXVIII  
TIEMPO APROXIMADO DE ENTRENAMIENTO POR MODELO

| Modelo              | Tiempo Promedio  |
|---------------------|------------------|
| Regresión Logística | 20 – 30 segundos |
| XGBoost             | 1 minuto         |
| Red Neuronal        | 3 – 4 minutos    |
| Random Forest       | 8 – 12 minutos   |

La Regresión Logística fue el algoritmo más eficiente computacionalmente, mientras que Random Forest presentó los mayores tiempos de entrenamiento sin traducirse en una mejora significativa del desempeño predictivo.

Por el contrario, XGBoost logró el mejor equilibrio entre precisión predictiva y costo computacional, alcanzando las mejores métricas globales con tiempos de entrenamiento considerablemente inferiores a los observados en Random Forest.

## V. CONCLUSIONES

El presente trabajo evaluó la capacidad de diferentes algoritmos de aprendizaje automático para predecir el desempeño académico de estudiantes colombianos en las pruebas Saber 11 a partir de variables sociodemográficas y características del entorno familiar y educativo.

Los resultados obtenidos demuestran que este tipo de variables contiene información predictiva relevante sobre el rendimiento académico, aunque su capacidad explicativa es moderada cuando se intenta discriminar múltiples niveles de desempeño.

En el escenario multiclase, la Red Neuronal Artificial obtuvo el mejor resultado según el criterio principal de evaluación (F1-score Macro = 0.5214), evidenciando una mayor capacidad para balancear el desempeño entre categorías y capturar relaciones complejas entre las variables predictoras. No obstante, XGBoost alcanzó la mayor exactitud global (Accuracy = 68.09).

Cuando el problema fue reformulado como una clasificación binaria, todos los modelos experimentaron mejoras importantes. En este escenario, XGBoost obtuvo el mejor desempeño general, alcanzando un Accuracy de 70.85.

Respecto al tratamiento de valores faltantes, la estrategia de imputación produjo consistentemente mejores resultados que la eliminación de registros incompletos. Aunque las diferencias observadas fueron moderadas, la conservación de una mayor cantidad de información disponible permitió obtener modelos más robustos y con mejor capacidad predictiva.

Desde la perspectiva computacional, la Regresión Logística destacó por su rapidez y facilidad de interpretación, constituyendo una línea base sólida para futuros trabajos. Por otro lado, Random Forest presentó los mayores tiempos de entrenamiento sin traducirse en mejoras significativas del desempeño. XGBoost logró el mejor equilibrio entre precisión predictiva, robustez y eficiencia computacional, razón por la cual fue seleccionado como modelo final para la implementación de la aplicación desarrollada.

Adicionalmente, se realizó un análisis de importancia de variables sobre el modelo XGBoost ganador. Los resultados mostraron que factores asociados al acceso a recursos tecnológicos en el hogar, como la disponibilidad de computador e internet, constituyen algunos de los predictores más influyentes del desempeño académico. Asimismo, variables relacionadas con la jornada escolar, el departamento de residencia y el nivel educativo de los padres también presentaron contribuciones relevantes dentro del proceso de decisión del modelo.

La Figura 29 presenta las veinte variables con mayor importancia para las predicciones realizadas por el modelo final.




Fig. 29. Importancia de variables del modelo XGBoost seleccionado para clasificación binaria.

Los hallazgos obtenidos son consistentes con la literatura especializada sobre predicción del rendimiento académico, la cual reporta una fuerte influencia de factores socioeconómicos, familiares y de acceso a recursos educativos sobre los resultados obtenidos por los estudiantes en pruebas estandarizadas.

Finalmente, este trabajo demuestra que las variables sociodemográficas permiten construir modelos con una capacidad predictiva razonable para la identificación temprana de estudiantes con mayor probabilidad de presentar bajo desempeño académico. Como trabajo futuro, se propone incorporar variables académicas históricas, información institucional

adicional y técnicas más avanzadas de ingeniería de características e interpretabilidad, con el fin de mejorar la capacidad predictiva de los modelos desarrollados.

## VI. BIBLIOGRAFÍA

### REFERENCES

- [1] P. Cortez and A. Silva, "Using Data Mining to Predict Secondary School Student Performance," in *Proceedings of the 5th Future Business Technology Conference*, Porto, Portugal, 2008, pp. 5–12.
- [2] D. A. Ahlburg, "Does Schooling Matter? The Relationship Between Education and Academic Performance," *Economics of Education Review*, vol. 25, no. 3, pp. 315–331, 2006.
- [3] S. B. Kotsiantis, C. J. Pierrakeas, and P. E. Pintelas, "Predicting Students' Performance in Distance Learning Using Machine Learning Techniques," *Applied Artificial Intelligence*, vol. 18, no. 5, pp. 411–426, 2004.
- [4] C. Romero and S. Ventura, "Educational Data Mining: A Review of the State of the Art," *IEEE Transactions on Systems, Man, and Cybernetics, Part C*, vol. 40, no. 6, pp. 601–618, 2010.
- [5] S. Huang and N. Fang, "Predicting Student Academic Performance in an Engineering Dynamics Course: A Comparison of Four Types of Predictive Mathematical Models," *Computers & Education*, vol. 61, pp. 133–145, 2020.
- [6] H. Waheed, S. Hassan, N. Aljohani, J. Hardman, R. Alelaiwi, and F. Nawaz, "Predicting Academic Performance of Students from VLE Big Data Using Deep Learning Models," *Computers in Human Behavior*, vol. 104, pp. 106189, 2020.
- [7] R. Asif, A. Merceron, S. A. Ali, and N. G. Haider, "Analyzing Undergraduate Students' Performance Using Educational Data Mining," *Computers & Education*, vol. 113, pp. 177–194, 2017.
- [8] G. Gray, C. McGuinness, and P. Owende, "An Application of Classification Models to Predict Learner Progression in Third Level Education," in *IEEE International Advance Computing Conference*, 2014, pp. 549–554.
- [9] S. Helal, J. Li, L. Liu, E. Ebrahimie, S. Dawson, and D. J. Murray, "Predicting Academic Performance by Considering Student Heterogeneity," *Knowledge-Based Systems*, vol. 161, pp. 134–146, 2018.
- [10] F. Ahmad, N. H. Ismail, and A. A. Aziz, "The Prediction of Students' Academic Performance Using Classification Data Mining Techniques," *Applied Mathematical Sciences*, vol. 9, no. 129, pp. 6415–6426, 2018.
- [11] I. H. Sarker, "Machine Learning: Algorithms, Real-World Applications and Research Directions," *SN Computer Science*, vol. 2, no. 3, pp. 1–21, 2021.
- [12] B. Al-Breiki, M. Zaki, A. Alashwal, and N. Mohamed, "A Systematic Literature Review of Student Performance Prediction Using Machine Learning Techniques," *Education and Information Technologies*, vol. 26, no. 5, pp. 5837–5869, 2021.
- [13] M. Rastrollo-Guerrero, J. Gómez-Pulido, and A. Durán-Domínguez, "Analyzing and Predicting Students' Performance by Means of Machine Learning: A Review," *Applied Sciences*, vol. 10, no. 3, pp. 1042, 2020.
- [14] Instituto Colombiano para la Evaluación de la Educación (ICFES), "Guía de Interpretación y Uso de Resultados de las Pruebas Saber 11," Bogotá, Colombia, 2023.
- [15] S. Raschka, Y. Liu, and V. Mirjalili, *Machine Learning with PyTorch and Scikit-Learn*. Birmingham, U.K.: Packt Publishing, 2022.
- [16] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.
- [17] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.